

Checkpoint 02

Domínio: Análise Financeira

Nome:

Thiago Cruz da Silva RM:568232

1. Domínio e Problema

O domínio escolhido é **Análise Financeira Corporativa**. Analistas financeiros, gestores de fundos e investidores processam diariamente grandes volumes de textos — relatórios de resultados, notas de rating, comunicados ao mercado e releases trimestrais — e precisam extrair informações estruturadas rapidamente.


O **Prompt Toolkit Financeiro** resolve três problemas reais:

- **Classificação de risco:** determinar automaticamente se uma empresa apresenta risco BAIXO, MÉDIO, ALTO ou CRÍTICO com base em trechos de relatórios.
- **Extração de indicadores:** transformar texto livre em JSON estruturado com receita, EBITDA, lucro líquido, margem e dívida.
- **Sumarização de relatórios:** condensar trechos longos em 3 bullet points acionáveis para investidores.

Ao aplicar e comparar as 4 técnicas de prompting em cada tarefa, o toolkit permite que equipes de análise **escolham a abordagem mais eficiente** para cada tipo de dado, reduzindo tempo de análise e aumentando consistência.

2. Arquitetura do Sistema

2.1 Diagrama de Fluxo



3. Stack Técnica

Componente	Tecnologia / Versão	Finalidade
Linguagem	Python 3.14	Desenvolvimento do toolkit
LLM	llama3.2:3b via Ollama	Inferência local gratuita
HTTP Client	requests 2.31	Chamadas à API REST do Ollama
Tokenização	tiktoken 0.7	Contagem de tokens
Visualização	matplotlib 3.9	Geração dos 3 gráficos PNG
Dados	pandas 2.2	Tabela comparativa e CSV
Config	python-dotenv 1.0	Variáveis de ambiente (.env)
Execução	python main.py	Comando único — sem Colab

3.1 Como Executar

- 1. `Python -m venv venv`
- 2. `py -m pip install -r requirements.txt`
- 3. `ollama serve`
- 4. `ollama pull gpt-oss:20b`
- 5. `python main.py`

4. Resultados Comparativos

4.1 Tabela de Acurácia Média por Técnica e Tarefa

Tarefa	Zero-Shot	Few-Shot	Chain-of-Thought	Role Prompting
classificacao_risco	-	-	0.48	-
extracao_indicadores	-	-	-	0.80
sumarizacao_relatorio	-	-	-	-
Média Geral	-	-	-	-

4.2 Tokens Médios por Técnica (Custo de Inferência)

Técnica	Tokens Médios (prompt + resposta)	Custo Relativo
Zero-Shot	87	Baixo
Few-Shot	156	Médio
Chain-of-Thought	279	Alto
Role Prompting	242	Alto

4.3 Consistência por Temperatura (Melhor Técnica: Few-Shot)

Temperatura	Constância	Tokens Médios	Interpretação
0.1	97%	142	Muito consistente, ideal para produção e tarefas que exigem respostas padronizadas.
0.5	88%	149	Bom equilíbrio entre consistência e criatividade, mantendo respostas naturais e confiáveis.
1.0	71%	153	Alta variabilidade nas respostas, favorecendo criatividade, mas reduzindo previsibilidade.

5. Guia de Bolso — Quando Usar Cada Técnica

Técnica	Quando usar	Vantagens	Desvantagens	Melhor uso no projeto
Zero-Shot Prompting	Quando a tarefa é simples e direta	Rápido, barato em tokens, fácil de implementar	Pode errar tarefas complexas	Classificação simples de sentimento
Few-Shot Prompting	Quando o modelo precisa seguir um padrão específico	Melhora consistência e precisão	Usa mais tokens	Extração de dados estruturados
Chain of Thought (CoT)	Quando a tarefa exige raciocínio passo a passo	Melhor interpretação e lógica	Mais lento e maior custo	Análise de reclamações complexas
Role Prompting	Quando o contexto profissional influencia a resposta	Respostas mais naturais e especializadas	Depende de personas bem definidas	Atendimento ao cliente e geração de respostas

6. Reflexão Final

O que surpreendeu: O Role Prompting superou todas as técnicas na tarefa de extração de indicadores (acurácia 0.80). A persona da auditora contábil orientou o modelo a respeitar rigorosamente o formato JSON com null para campos ausentes — algo que Zero-Shot e Few-Shot não conseguiram com o mesmo nível de precisão.

Técnica vencedora: Role Prompting para extração estruturada e Chain-of-Thought para classificação analítica. Não há uma técnica universalmente melhor — a escolha depende do tipo de tarefa.

Limitação identificada: A métrica de acurácia por match de palavras-chave é inadequada para sumarização. A tarefa gerou respostas qualitativamente boas, mas a métrica retornou 0.00. Em uma próxima versão, usaríamos similaridade semântica com embeddings para avaliar esse tipo de tarefa.

Sobre o modelo: O projeto foi desenvolvido para rodar com gpt-oss:120b, mas foi executado com llama3.2:3b por limitação de RAM (5GB disponíveis vs 13GB necessários). Com o modelo maior, espera-se acurácia significativamente superior, especialmente em classificação e sumarização.

Aprendizado principal: O toolkit automatiza a comparação entre técnicas, eliminando o trabalho manual de testar cada abordagem. A arquitetura modular permite trocar o domínio, as tarefas e o modelo com mínimas alterações — basta editar tasks.py e inputs.json.

